

Thuật toán K-Means - Khái niệm & Trọng tâm

① Bản chất

- K-Means là thuật toán phân cụm (Clustering) tiêu biểu thuộc nhóm Học không giám sát (Unsupervised Learning).

② Mục tiêu

- Phân chia tập dữ liệu X thành K cụm rời rạc sao cho các điểm trong cùng một cụm có độ tương đồng cao nhất (khoảng cách gần nhất).

③ Lưu ý khởi tạo

- Trong thực tế, kỹ sư thường dùng phương pháp **K-Means++** để chọn các tâm cụm ban đầu nằm xa nhau, giúp thuật toán hội tụ nhanh và tránh kẹt ở mức tối ưu cục bộ.

Thuật toán K-Means - Các bước thực thi

Thuật toán vận hành qua vòng lặp của 4 bước cốt lõi:

❶ Khởi tạo (Initialization)

Chọn ngẫu nhiên K điểm làm tâm cụm (Centroids).

❷ Gán cụm (Assignment)

Tính khoảng cách Euclidean từ mỗi điểm dữ liệu đến K tâm cụm.

Gán điểm đó vào cụm có tâm gần nhất.

❸ Cập nhật tâm (Update)

Đời vị trí của mỗi tâm cụm về giá trị trung bình tọa độ (Mean) của tất cả các điểm vừa được gán vào cụm đó.

❹ Hội tụ (Convergence)

Lặp lại Bước 2 và Bước 3 cho đến khi vị trí các tâm cụm không còn thay đổi.

Hàm mục tiêu K-Means & Tối ưu số lượng cụm

1. Hàm WCSS (Within-Cluster Sum of Squares)

- K-Means hoạt động dựa trên việc cực tiểu hóa khoảng cách nội cụm.

$$\mathcal{L}(Y, M) = \sum_{i=1}^N \sum_{j=1}^K y_{ij} \|x_i - m_j\|_2^2$$

Trong đó:

- N : Tổng số mẫu.
- K : Số cụm.
- y_{ij} : Biến chỉ báo gán cụm.
- m_j : Tâm cụm.
- x_i : Điểm dữ liệu.

Tối ưu số lượng cụm

Phương pháp chọn số K tối ưu

1 Elbow Method (Phương pháp khuỷu tay)

- Vẽ đồ thị WCSS theo K .
- Chọn K tại điểm đồ thị chứng lại tốc độ giảm (tạo thành nếp gấp).

2 Silhouette Score

- Đo lường độ tách bạch của các cụm.
- Giá trị nằm trong khoảng từ -1 đến 1 .
- Càng gần 1 , cụm càng chất lượng.

Chiến lược phân chia dữ liệu (Data Splitting)

Nguyên tắc tối thượng

- Tránh Rò rỉ dữ liệu (Data Leakage).

① Train Set (70%)

Dữ liệu để mô hình trực tiếp học và điều chỉnh các trọng số.

② Validation Set (15%)

"Bài thi thử".

Dùng để theo dõi quá trình học, tinh chỉnh Siêu tham số (Hyperparameters) và chọn ra phiên bản mô hình tốt nhất.

③ Test Set (15%)

"Bài thi thật".

Bị cách ly hoàn toàn trong lúc huấn luyện, chỉ được dùng đúng **một lần** cuối cùng để báo cáo hiệu suất khách quan.

Cross Validation (Kiểm tra chéo)

Trường hợp áp dụng

- Dữ liệu quá nhỏ, nếu chia Train/Test một lần sẽ mang tính ngẫu nhiên, dẫn đến Overfitting trên chính tập Validation cố định.

K-fold Cross Validation

- Chia dữ liệu thành K phần (folds).
- Lặp lại việc huấn luyện K lần.
- Mỗi lần lấy 1 phần làm Validation, $K - 1$ phần làm Train.
- Điểm số là trung bình của K lần chạy.
- Giúp so sánh mô hình (Model Selection) khách quan hơn.

Stratified K-fold

- Dành cho dữ liệu mất cân bằng nghiêm trọng.
- Giữ nguyên tỷ lệ phân phối các lớp (ví dụ 9:1) trong mọi fold.

Đánh giá mô hình Hồi quy (Regression) - Phần 1

Đo lường Phần dư (Residuals)

- Là sự chênh lệch giữa giá trị thực tế y_i và giá trị dự đoán $\hat{y}_i$.

1. MAE (Mean Absolute Error)

- Trung bình trị tuyệt đối của sai số.
- Có cùng đơn vị với dữ liệu gốc.
- Ít bị ảnh hưởng bởi các giá trị ngoại lai (outliers).

$$MAE = \frac{1}{N} \sum_{i=1}^N |y_i - \hat{y}_i|$$

2. MSE (Mean Squared Error)

- Tính bình phương sai số trước khi lấy trung bình.
- Việc bình phương sẽ phạt cực kỳ nặng những điểm mô hình đoán sai lệch quá xa.

$$MSE = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2$$

Đánh giá mô hình Hồi quy (Regression) - Phần 2

1. RMSE (Root Mean Squared Error)

- Là căn bậc hai của MSE.
- Đưa sai số trở về cùng đơn vị với dữ liệu gốc.

$$RMSE = \sqrt{\frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2}$$

2. R^2 Score

- Hệ số xác định trong khoảng $[0, 1]$.
- Đo tỷ lệ biến thiên của dữ liệu được mô hình giải thích.

$$R^2 = 1 - \frac{\sum_{i=1}^N (y_i - \hat{y}_i)^2}{\sum_{i=1}^N (y_i - \bar{y})^2}$$

Ma trận nhầm lẫn (Confusion Matrix)

Các thành phần của Confusion Matrix

- **True Positive (TP):** Lớp thực tế là Positive → Mô hình dự đoán **ĐÚNG** là Positive.
- **True Negative (TN):** Lớp thực tế là Negative → Mô hình dự đoán **ĐÚNG** là Negative.
- **False Positive (FP):** Lớp thực tế là Negative → Mô hình dự đoán **SAI** thành Positive. (*Báo động giả / Sai số loại I*).
- **False Negative (FN):** Lớp thực tế là Positive → Mô hình dự đoán **SAI** thành Negative. (*Bỏ lọt mục tiêu / Sai số loại II*).

		Predicted values	
		Positive (cat)	Negative (not cat)
Actual values	Positive (cat)	True positive  This is a cat.	False negative  This is not a cat. Type 2 error
	Negative (not cat)	False positive  This is a cat. Type 1 error	True negative  This is not a cat.

Precision & Recall

Precision (Độ chính xác)

- **Khẩu quyết:** “Trong số những điểm được phân loại là Positive, có bao nhiêu điểm là True Positive (đúng)?”

$$\text{Precision} = \frac{TP}{TP + FP}$$

Ý nghĩa: Precision cao đồng nghĩa với việc độ chính xác của các điểm tìm được là cao.

Recall (Độ phủ / True Positive Rate)

- **Khẩu quyết:** “Trong số những điểm thực sự là Positive, có bao nhiêu điểm là True Positive (đúng)?”

$$\text{Recall} = \frac{TP}{TP + FN}$$

Ý nghĩa: Recall cao đồng nghĩa với việc tỉ lệ bỏ sót các điểm thực sự Positive là thấp.

F1-Score (Chỉ số hài hòa)

Tại sao cần F1-Score?

Để tránh việc mô hình đánh lừa bằng cách hy sinh hoàn toàn một chỉ số để đẩy chỉ số còn lại lên mức 100%.

Công thức

Là trung bình điều hòa (Harmonic Mean) của Precision và Recall.

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

Đặc điểm

- Mô hình bị “trừng phạt” rất nặng nếu một trong hai chỉ số có giá trị quá thấp.
- Chỉ đạt điểm cao khi **cả Precision và Recall** đều ở mức cao.

Kết luận

F1-Score là thước đo tiêu chuẩn để đánh giá hiệu năng tổng thể của mô hình trên dữ liệu mất cân bằng.

Phân tích thành phần sai số: Bias & Variance

① Irreducible Error

- Sai số do bản chất dữ liệu.
- Không thể loại bỏ dù mô hình hoàn hảo.

② Bias (Thiên kiến)

- Sai lệch giữa dự đoán trung bình và thực tế.
- Nguyên nhân: Mô hình quá đơn giản.
- Hậu quả: Underfitting.

③ Variance (Độ phân tán)

- Độ nhạy với biến động của tập Train.
- Nguyên nhân: Mô hình quá phức tạp.
- Hậu quả: Overfitting.

Bias-Variance Trade-off & Learning Curve

1. Bias-Variance Trade-off

- Khi tăng độ phức tạp mô hình:
 - Bias giảm.
 - Variance tăng.
- Mục tiêu là tìm được **Sweet Spot** để tổng sai số đạt cực tiểu.

2. Learning Curve

- Learning Curve biểu diễn mối quan hệ giữa Error/Loss và Epoch hoặc kích thước dữ liệu Train.
- Theo dõi Learning Curve giúp nhận biết:
 - High Bias (Underfitting).
 - High Variance (Overfitting).
 - Good Fit.

Kỹ thuật Điều chuẩn (Regularization)

Ý tưởng

- Thêm một "khoản phạt" (λ) vào Hàm mất mát ban đầu ($\mathcal{L}_0$) để kiểm soát độ phức tạp của mô hình.

1. L1 Regularization (Lasso)

- Phạt theo trị tuyệt đối.
- Có khả năng triệt tiêu hẳn trọng số của các đặc trưng không quan trọng về 0.
- Hoạt động như một bộ lọc (Feature Selection).

$$\mathcal{L}_{L1} = \mathcal{L}_0 + \lambda \sum_{j=1}^p |w_j|$$

2. L2 Regularization (Ridge)

- Phạt theo bình phương.

Điều chuẩn trong Deep Learning & Early Stopping

1. Dropout (Mạng Neural)

- **Cơ chế:** Ngẫu nhiên vô hiệu hóa (tắt) một tỷ lệ nơ-ron nhất định (VD: 20%) trong mỗi vòng lặp.
- **Tác dụng:** Ngăn chặn các nơ-ron "dựa dẫm" vào nhau (co-adaptation), ép mỗi nơ-ron phải tự phân tích ra những đặc trưng độc lập.

2. Early Stopping

- Theo dõi sát sao đường cong Validation Loss.
- Nếu Validation Loss không giảm mà bắt đầu tăng ngược lại (dấu hiệu Overfitting), hệ thống lập tức dừng train.
- Khôi phục bộ trọng số (weights) tốt nhất trước thời điểm Overfitting.

Ensemble Methods (Học kết hợp)

Giải quyết bài toán Bias–Variance bằng cách kết hợp nhiều **Base Learners** thành một hệ thống mạnh hơn.

1. Bagging (Bootstrap Aggregating)

- Ví dụ: Random Forest.
- Lấy mẫu ngẫu nhiên có hoàn lại (Bootstrap) để tạo nhiều tập dữ liệu con.
- Các mô hình được huấn luyện song song và độc lập.
- Tổng hợp bằng Majority Voting hoặc Averaging.
- Giảm Variance và chống Overfitting rất hiệu quả.

2. Boosting

- Ví dụ: XGBoost, AdaBoost, Gradient Boosting.
- Các mô hình học nối tiếp nhau.
- Mô hình sau tập trung nhiều hơn vào các điểm mà mô hình trước dự đoán sai.