

Logistic Regression & Support Vector Machine

Trần Hải Nam (B24DCCN418)

figures/logo.png

Bộ môn XLTH & TT
Khoa Kỹ thuật Điện tử 1
Học viện Công nghệ Bưu chính Viễn thông

Ngày 13 tháng 05 năm 2026

Mục lục

figures/logo.png

Bản chất Hồi quy tuyến tính & Hàm mất mát

Bài toán: Hồi quy (Supervised Learning) – Học hàm ánh xạ từ features sang giá trị liên tục.

Mô hình: Giả định mối quan hệ tuyến tính giữa input $x \in \mathbb{R}^d$ và nhãn $y \in \mathbb{R}$.

$$\hat{y} = w^T x$$

- (Quy ước: thêm $x_0 = 1$ để gộp hệ số chệch w_0 ; mỗi w_i thể hiện mức độ đóng góp của x_i).

Sai số dự đoán (Residual):

$$e = y - Xw$$

Hàm mất mát (SSE): Cực tiểu hóa tổng bình phương sai số để phạt nặng các dự đoán sai lệch lớn.

$$\mathcal{L}(w) = \frac{1}{2} \sum_{i=1}^N e_i^2 = \frac{1}{2} \|y - Xw\|_2^2$$

Tối ưu tham số - Nghiệm dạng đóng

Mục tiêu: Tìm $w^* = \arg \min_w \mathcal{L}(w)$ bằng cách giải $\nabla_w \mathcal{L}(w) = 0$.

Chứng minh toán học:

Ta khai triển hàm mất mát dưới dạng nhân ma trận. Chú ý rằng chuẩn bậc 2 của một vectơ v là $\|v\|_2^2 = v^T v$:

figures/logo.png

$$\mathcal{L}(w) = \frac{1}{2}(y - Xw)^T(y - Xw)$$

$$\mathcal{L}(w) = \frac{1}{2}(y^T y - y^T Xw - w^T X^T y + w^T X^T Xw)$$

Tối ưu tham số - Nghiệm dạng đóng

Vì $y^T Xw$ là một số vô hướng (scalar), nên giá trị của nó bằng chính ma trận chuyển vị của nó:

$$y^T Xw = (y^T Xw)^T = w^T X^T y$$

Do đó:


$$\mathcal{L}(w) = \frac{1}{2} (y^T y - 2w^T X^T y + w^T X^T Xw)$$

Lấy đạo hàm của $\mathcal{L}(w)$ theo vectơ w :

$$\begin{aligned}\nabla_w \mathcal{L}(w) &= \frac{1}{2} (0 - 2X^T y + 2X^T Xw) \\ &= X^T Xw - X^T y\end{aligned}$$

Tối ưu tham số - Nghiệm dạng đóng

Cho đạo hàm bằng 0 để tìm điểm cực tiểu:

$$X^T X w - X^T y = 0 \implies X^T X w = X^T y$$

Từ đây, ta có công thức nghiệm tối ưu:

$$w^* = (X^T X)^\dagger X^T y$$

- (Ta dùng ma trận giả nghịch đảo $\dagger$ để phòng trường hợp $X^T X$ không khả nghịch).

Tối ưu tham số - Hạ Gradient (Gradient Descent)

Nhược điểm của Nghiệm dạng đóng: Chi phí tính ma trận nghịch đảo quá lớn khi dữ liệu/đặc trưng nhiều.

Hạ Gradient: Cập nhật lặp ngược chiều đạo hàm.

$$\mathbf{w}^{(t+1)} = \mathbf{w}^{(t)} - \eta \nabla_{\mathbf{w}} \mathcal{L}(\mathbf{w}^{(t)})$$


Thay kết quả đạo hàm đã chứng minh vào, ta có công thức cập nhật:

$$\mathbf{w}^{(t+1)} = \mathbf{w}^{(t)} - \eta \left(\mathbf{X}^T \mathbf{X} \mathbf{w}^{(t)} - \mathbf{X}^T \mathbf{y} \right)$$

Underfitting (High Bias)

1. Vấn đề: Underfitting (High Bias)

- **Bản chất:** Mô hình gốc $\hat{y} = w^T x$ là một đường thẳng quá cứng nhắc, không đủ năng lực học các quy luật phi tuyến phức tạp.
- **Dấu hiệu:** Sai số Train và Test đều rất lớn.



Giải pháp: Hồi quy đa thức (Polynomial Regression)


2. Giải pháp: Hồi quy đa thức (Polynomial Regression)

- Để mô hình có thể uốn lượn, ta biến đổi không gian đầu vào x thành các đặc trưng bậc cao:

figures/logo.png

$$\Phi(x) = [1, x, x^2, x^3, \dots, x^n]^T$$

- Mô hình lúc này trở thành đường cong:
 $\hat{y} = w^T \Phi(x)$.



Hệ quả khi lạm dụng: Overfitting (High Variance)


3. Hệ quả khi lạm dụng: Overfitting (High Variance)

Bản chất:

- Nếu chọn bậc đa thức n quá lớn, mô hình sẽ “học vẹt” từng điểm nhiễu ngẫu nhiên.
- Để đường cong bề lái liên tục qua mọi điểm dữ liệu, các hệ số trọng số w buộc phải bùng nổ lên những giá trị khổng lồ.

Dấu hiệu:

- Sai số Train tiến sát về 0.
- Sai số Test cực kỳ lớn.



Điều chuẩn Ridge (L2 Penalty)

Mục tiêu: Kìm hãm độ lớn của trọng số w (Weight Decay) để đạt Trạng thái cân bằng.

Ridge Regression: Phạt theo tổng bình phương trọng số.

$$\mathcal{J}(w) = \frac{1}{2} \|y - Xw\|_2^2 + \frac{\alpha}{2} \|w\|_2^2$$

Chứng minh toán học tìm w^* :

Đạo hàm hàm mất mát mới $\mathcal{J}(w)$ theo w . Chú ý rằng đạo hàm của phần đầu chính là $X^T Xw - X^T y$ (đã chứng minh ở mục 3), và đạo hàm của $\frac{\alpha}{2} \|w\|_2^2$ là αw :

Điều chuẩn Ridge (L2 Penalty)

$$\nabla_w \mathcal{J}(w) = (X^T X w - X^T y) + \alpha w = 0$$

Chuyển vế và nhóm w làm nhân tử chung (sử dụng ma trận đơn vị I cùng kích thước):

figures/logo.png

$$X^T X w + \alpha I w = X^T y$$

$$(X^T X + \alpha I) w = X^T y$$

Do biểu thức $(X^T X + \alpha I)$ luôn luôn là một ma trận xác định dương (positive definite) với mọi $\alpha > 0$, nên nó chắc chắn khả nghịch.

Điều chuẩn Ridge (L2 Penalty)

Ta nhân hai vế với ma trận nghịch đảo để ra công thức cuối cùng:

$$w^* = (X^T X + \alpha I)^{-1} X^T y$$

Ý nghĩa: α đảm bảo ma trận luôn khả nghịch. Ridge kéo w về gần 0, giúp mô hình mượt mà, ổn định.

Điều chuẩn Lasso (L1 Penalty)

Lasso Regression: Phạt theo tổng trị tuyệt đối trọng số.

$$\mathcal{J}(w) = \frac{1}{2} \|y - Xw\|_2^2 + \alpha \sum_{i=1}^d |w_i|$$

Đặc điểm Tối ưu:

- Hàm trị tuyệt đối có góc nhọn, không có đạo hàm tại $w = 0 \rightarrow$ Không có nghiệm dạng đóng.
- Sử dụng thuật toán lặn: Hạ tọa độ (Coordinate Descent).

Ý nghĩa: Đặc tính “góc nhọn” ép trực tiếp trọng số của biến không quan trọng về chính xác 0 $\rightarrow$ Trở thành bộ lọc đặc trưng (Feature Selection).

Các Metrics đánh giá (R-squared)

MSE: Trung bình bình phương sai số (phạt nặng dự đoán lệch lớn).

$$\text{MSE} = \frac{1}{N} \|y - Xw\|_2^2$$

RMSE: Căn bậc hai MSE (đưa về cùng đơn vị đo mục tiêu).

Hệ số xác định (R^2): Tỷ lệ phương sai dữ liệu mà mô hình giải thích được.

$$R^2 = 1 - \frac{\sum e_i^2}{\sum (y_i - \bar{y})^2} = 1 - \frac{SS_{res}}{SS_{tot}}$$

Các Metrics đánh giá (R-squared)

Adjusted R^2 : Khắc phục ảo giác R^2 luôn tăng khi thêm biến, bằng cách phạt theo số lượng biến k .

figures/logo.png

$$Adj R^2 = 1 - \frac{(1 - R^2)(n - 1)}{n - k - 1}$$