

Logistic Regression & Support Vector Machine

Trần Hải Nam (B24DCCN418)

Bộ môn XLTH & TT
Khoa Kỹ thuật Điện tử 1
Học viện Công nghệ Bưu chính Viễn thông

Ngày 13 tháng 05 năm 2026

1 Support Vector Machine (SVM)

```
[aspectratio=169]beamer [utf8]inputenc [T5]fontenc lmodern amsmath, amssymb, amsfonts  
bm  
[]beamerthemeMadrid []beamercolorthemedefault
```

MÔ HÌNH SUPPORT VECTOR MACHINE (SVM)

Báo cáo chi tiết: Hard Margin SVM

Người báo cáo

Bộ môn XLTH & TT
Khoa Kỹ thuật Điện tử 1
Học viện Công nghệ Bưu chính Viễn thông

July 28, 2026

1. Đặt vấn đề & Bản chất hình học của SVM

Lời dẫn dắt: Mục tiêu của SVM không chỉ đơn thuần là tìm một đường ranh giới phân loại, mà phải tìm ranh giới "*an toàn nhất*" cho dữ liệu trong không gian D chiều.

- **Siêu mặt phẳng phân chia (Hyperplane):** Được định nghĩa bởi phương trình $w^T x + b = 0$, có nhiệm vụ tách biệt hoàn toàn hai lớp dữ liệu mang nhãn $y_n \in \{-1, +1\}$.
- **Tối đa hóa khoảng cách lề (Maximum Margin):** Tìm siêu mặt phẳng sao cho khoảng cách từ nó đến các điểm dữ liệu gần nhất là lớn nhất nhằm chống khớp quá mức (overfitting).
- **Công thức khoảng cách:** Khoảng cách từ một điểm x_n bất kỳ đến siêu mặt phẳng được tính bằng:

$$\text{distance} = \frac{y_n(w^T x_n + b)}{\|w\|_2}$$

2. Bài toán tối ưu gốc (Primal Problem)

Lời dẫn dắt: Với giả thiết tập dữ liệu **phân tách tuyến tính hoàn toàn** (Linearly Separable), ta thiết lập bài toán tối ưu để tối đa hóa lề.

- **Chuẩn hóa lề:** Đặt điều kiện cho các điểm dữ liệu gần ranh giới nhất thỏa mãn:

$$y_n(w^T x_n + b) \geq 1$$

- **Thiết lập bài toán:** Tối đa hóa lề $\frac{1}{\|w\|_2}$ tương đương với bài toán tối ưu lồi có ràng buộc:

Bài toán tối ưu gốc (Primal Problem)

$$\min_{w,b} \frac{1}{2} \|w\|_2^2 \quad \text{s.t.} \quad y_n(w^T x_n + b) \geq 1, \quad \forall n = 1, 2, \dots, N$$

- **Đặc điểm:** Hàm mục tiêu lồi kết hợp ràng buộc tuyến tính $\implies$ Luôn tồn tại nghiệm tối ưu toàn cục duy nhất.

3. Xây dựng hàm Lagrangian & Điều kiện dừng

Lời dẫn dắt: Để giải bài toán có ràng buộc bất đẳng thức, ta chuyển về bài toán không ràng buộc bằng cách đưa vào các nhân tử Lagrange.

- **Hàm Lagrangian ($\mathcal{L}$):** Với các nhân tử $\lambda_n \geq 0$:

$$\mathcal{L}(w, b, \lambda) = \frac{1}{2} \|w\|_2^2 - \sum_{n=1}^N \lambda_n \left(y_n (w^T x_n + b) - 1 \right)$$

- **Điều kiện dừng (Stationarity):** Đạo hàm riêng theo các biến gốc w và b tại điểm tối ưu phải triệt tiêu (bằng 0):

$$\nabla_w \mathcal{L} = w - \sum_{n=1}^N \lambda_n y_n x_n = 0 \implies w = \sum_{n=1}^N \lambda_n y_n x_n$$

$$\frac{\partial \mathcal{L}}{\partial b} = - \sum_{n=1}^N \lambda_n y_n = 0 \implies \sum_{n=1}^N \lambda_n y_n = 0$$

4. Bài toán tối ưu đối ngẫu (Dual Problem)

Lời dẫn dắt: Thay thế điều kiện dừng ngược lại vào hàm Lagrangian, ta triệt tiêu được hoàn toàn biến w và b , thu được bài toán đối ngẫu chỉ theo λ .

Bài toán tối ưu đối ngẫu (Dual Problem)

Hàm mục tiêu đối ngẫu:

$$\max_{\lambda} \sum_{n=1}^N \lambda_n - \frac{1}{2} \sum_{n=1}^N \sum_{m=1}^N \lambda_n \lambda_m y_n y_m (x_n^T x_m)$$

Các ràng buộc đối ngẫu:

$$\sum_{n=1}^N \lambda_n y_n = 0 \quad \text{và} \quad \lambda_n \geq 0, \quad \forall n = 1, 2, \dots, N$$

5. Hệ điều kiện KKT (Karush-Kuhn-Tucker)

Để nghiệm tìm được là tối ưu toàn cục, bộ tham số phải thỏa mãn đồng thời 4 nhóm điều kiện KKT bắt buộc sau ($\forall n = 1, \dots, N$):

① **Khả thi gốc (Primal Feasibility):**

$$y_n(w^T x_n + b) - 1 \geq 0$$

② **Khả thi đối ngẫu (Dual Feasibility):**

$$\lambda_n \geq 0$$

③ **Điều kiện dừng (Stationarity):**

$$w = \sum_{n=1}^N \lambda_n y_n x_n \quad \text{và} \quad \sum_{n=1}^N \lambda_n y_n = 0$$

④ **Bù nhàn rỗi (Complementary Slackness):**

$$\lambda_n (y_n(w^T x_n + b) - 1) = 0$$

6. Bản chất của Support Vectors

Lời dẫn dắt: Từ điều kiện *Bù nhàn rỗi*, ta phát hiện ra tính chất tuyệt vời: toàn bộ mô hình chỉ được quyết định bởi một vài điểm dữ liệu đặc biệt!

- **Điểm thông thường (Nằm sâu bên trong lề):**

- Thỏa mãn strict inequality: $y_n(w^T x_n + b) > 1$
- Bắt buộc nhân tử $\lambda_n = 0 \implies$ Không có bất kỳ đóng góp nào vào siêu mặt phẳng.

- **Support Vectors (Nằm sát mép lề):**

- Là các điểm có nhân tử $\lambda_n > 0$.
- Để tích bù nhàn rỗi bằng 0, bắt buộc phần ngoặc phải bằng 0:

$$y_n(w^T x_n + b) = 1$$

- **Kết luận:** Siêu mặt phẳng tối ưu chỉ phụ thuộc vào tập con rất nhỏ các điểm Support Vectors này.

7. Tính toán tham số & Quy tắc dự đoán

Lời dẫn dắt: Sau khi giải được bài toán đôi ngẫu để tìm λ , ta khôi phục lại các tham số của mô hình để thực hiện phân lớp cho dữ liệu mới.

- **Vector pháp tuyến w :** (Tổng hợp trên tập Support Vectors $\mathcal{S} = \{n \mid \lambda_n > 0\}$)

$$w = \sum_{n \in \mathcal{S}} \lambda_n y_n x_n$$

- **Hệ số tự do b :** Dựa vào Support Vector bất kỳ x_s (nhân 2 về cho y_s vì $y_s^2 = 1$):

$$b = y_s - w^T x_s \quad (\text{cho mọi } s \in \mathcal{S})$$

- **Hàm quyết định cho điểm dữ liệu mới (x):**

Quy tắc phân lớp

$$f(x) = \text{sgn} \left(w^T x + b \right) = \text{sgn} \left(\sum_{m \in \mathcal{S}} \lambda_m y_m (x_m^T x) + b \right)$$

===== Slide 1 =====

Giới hạn của Hard Margin SVM

1. Đặt vấn đề

- Hard Margin SVM giả sử dữ liệu **phân tách tuyến tính hoàn toàn** (Linearly Separable).
- Trong thực tế giả định này thường không thỏa mãn.

2. Nhược điểm

- **Vô nghiệm khi có nhiễu (Noise/Outliers):** Chỉ cần một vài điểm ngoại lai, bài toán không còn tồn tại siêu mặt phẳng thỏa mãn mọi ràng buộc.
- **Overfitting:** Ép mô hình phân loại đúng tuyệt đối làm **margin** bị thu hẹp, giảm khả năng tổng quát hóa.

3. Giải pháp: Soft Margin SVM

- Cho phép một số điểm dữ liệu vi phạm margin hoặc bị phân loại sai.
- Đổi lại mô hình vẫn giữ được margin lớn, chống nhiễu và tổng quát hóa tốt hơn.

Bài toán tối ưu gốc (Primal Problem)

1. Slack Variables & Ràng buộc mới

- Biến chùng $\xi_n \geq 0$ đo mức độ vi phạm margin:

$$y_n(w^T x_n + b) \geq 1 - \xi_n$$

- $\xi_n = 0$: An toàn; $0 < \xi_n < 1$: Trong margin; $\xi_n \geq 1$: Sai lớp.


2. Hàm mục tiêu và Điều kiện

$$\min_{w, b, \xi} \frac{1}{2} \|w\|_2^2 + C \sum_{n=1}^N \xi_n \quad \text{s.t.} \quad y_n(w^T x_n + b) \geq 1 - \xi_n, \xi_n \geq 0$$

3. Ý nghĩa tham số C

- C **lớn**: Phạt nặng vi phạm, mô hình gần Hard Margin (dễ Overfitting).
- C **nhỏ**: Ưu tiên margin rộng, chống nhiễu tốt (dễ Underfitting).

Minh họa hình học: Ý nghĩa biến chùng ξ_n



Phân tích các trường hợp:

- **An toàn ($\xi_n = 0$):** Các điểm nằm đúng phía và ở ngoài hoặc ngay trên đường margin (những điểm được khoanh tròn là Support Vectors).
- **Vi phạm lề (x_2 với $0 < \xi_2 < 1$):** Phân loại đúng lớp nhưng nằm lọt vào bên trong vùng margin.
- **Phân loại sai (x_1, x_3 với $\xi_1, \xi_3 > 1$):** Nằm vượt qua hẳn siêu mặt phẳng phân chia $w^T x + b = 0$ sang vùng của lớp đối diện.

Xây dựng bài toán đối ngẫu

1. Hàm Lagrangian

$$\begin{aligned}\mathcal{L}(w, b, \xi, \lambda, \mu) = & \frac{1}{2} \|w\|_2^2 + C \sum_{n=1}^N \xi_n \\ & + \sum_{n=1}^N \lambda_n (1 - \xi_n - y_n(w^T x_n + b)) - \sum_{n=1}^N \mu_n \xi_n\end{aligned}$$

2. Điều kiện dừng (Stationarity)

$$w = \sum_{n=1}^N \lambda_n y_n x_n, \quad \sum_{n=1}^N \lambda_n y_n = 0, \quad \lambda_n = C - \mu_n \implies 0 \leq \lambda_n \leq C$$

Thay các điều kiện trên vào hàm Lagrangian để triệt tiêu các biến gốc w, b, ξ , thu được bài toán đối ngẫu ở slide tiếp theo.

Kết quả bài toán đối ngẫu

1. Hàm mục tiêu đối ngẫu

$$\max_{\lambda} \sum_{n=1}^N \lambda_n - \frac{1}{2} \sum_{n=1}^N \sum_{m=1}^N \lambda_n \lambda_m y_n y_m x_n^T x_m$$

2. Các ràng buộc đối ngẫu

- $\sum_{n=1}^N \lambda_n y_n = 0$

- $0 \leq \lambda_n \leq C, \quad \forall n = 1, 2, \dots, N$

(Điểm khác biệt duy nhất so với Hard Margin là có chặn trên C nhờ biến chùng ξ_n).

Hệ điều kiện KKT (Karush-Kuhn-Tucker)

Để nghiệm đạt tối ưu toàn cục, hệ điều kiện KKT phải thỏa mãn các nhóm phương trình ràng buộc sau cho mọi điểm dữ liệu $n = 1, 2, \dots, N$:

- **Khả thi gốc (Primal Feasibility):**

$$1 - \xi_n - y_n(w^T x_n + b) \leq 0, \quad \xi_n \geq 0$$

- **Khả thi đối ngẫu (Dual Feasibility):**

$$\lambda_n \geq 0, \quad \mu_n \geq 0$$

- **Bù nhàn rỗi (Complementary Slackness):**

$$\lambda_n(1 - \xi_n - y_n(w^T x_n + b)) = 0, \quad \mu_n \xi_n = 0$$

- **Điều kiện dừng (Stationarity):**

$$\lambda_n = C - \mu_n \implies 0 \leq \lambda_n \leq C$$

Phân loại dữ liệu KKT & Tính toán tham số

Nhóm điểm dữ liệu	Giá trị λ_n & μ_n	Biến chùng ξ_n & Vị trí	Vai trò & Tính chất trong mô hình
1. Điểm an toàn (Non-support Vectors)	$\lambda_n = 0$ $(\mu_n = C \neq 0)$	$\xi_n = 0$ $(y_n z_n > 1)$	Không có vi phạm. Điểm nằm sâu trong vùng an toàn, bị máy tính bỏ qua.
2. Support Vector chuẩn (Margin Bound - S_{mb})	$0 < \lambda_n < C$ $(\mu_n \neq 0)$	$\xi_n = 0$	Nằm vừa vặn trên mép lề ($y_n z_n = 1$). Nhóm mốc dùng để tính hệ số tự do b .
3. Support Vector vi phạm (Violated Points)	$\lambda_n = C$ $(\mu_n = 0)$	$\xi_n > 0$ (Lọt vào / Sai lớp)	Vi phạm lề hoặc sai lớp. Nhân tử đạt trần C , tạo lực đẩy hình thành ranh giới.

Công thức xác định siêu phẳng tối ưu (w, b) từ các Support Vector:

- **Vector pháp tuyến w :** Chỉ phụ thuộc vào các Support Vector ($\lambda_n > 0$):

$$w = \sum_{n \in S} \lambda_n y_n x_n \quad \text{với } S = \{n \mid \lambda_n > 0\}$$

- **Hệ số tự do b :** Tính trung bình trên nhóm **Support Vector chuẩn**:

Góc nhìn Hinge Loss & Vấn đề bất ổn định nghiệm

1. Hàm mất mát Hinge Loss:

- Để tối thiểu hóa vi phạm của biên chùng ξ_n , ta sử dụng Hinge Loss:

$$L(w, b) = \sum_{n=1}^N \max(0, 1 - y_n(w^T x_n + b))$$

2. Vấn đề "Bất ổn định nghiệm" nếu chỉ dùng Hinge Loss:

- Giả sử (w, b) phân loại đúng toàn bộ dữ liệu, tức là:

$$1 - y_n(w^T x_n + b) \leq 0, \quad \forall n = 1, 2, \dots, N$$

- Nếu nhân cả hai vế với một hằng số $a > 1$, ta có:

$$1 - y_n(aw^T x_n + ab) \leq 1 - a < 0$$

- Hệ quả:** Do giá trị bên trong ≤ 0 , hàm loss tại (aw, ab) vẫn bằng 0!
- Nếu không có ràng buộc, các hệ số có thể **lớn tùy ý**, gây ra *overfitting*.

Giải pháp: Thêm L2 Regularization (Weight Decay)

3. Giải pháp khắc phục (Weight Decay):

- Để ngăn các hệ số (w, b) tăng lên quá lớn, ta cộng thêm thành phần điều chuẩn $\frac{\lambda}{2} \|w\|_2^2$ vào hàm mất mát.
- Khi đó, hàm mất mát của **Soft Margin SVM** trở thành:

$$\mathcal{J}(w, b) = \sum_{n=1}^N \max(0, 1 - y_n(w^T x_n + b)) + \frac{\lambda}{2} \|w\|_2^2$$

Sự thống nhất giữa hai góc nhìn

Thêm L2 Regularization ở góc nhìn này chính là **tối đa hóa khoảng cách lề** ở bài toán gốc. Hai cách tiếp cận hoàn toàn tương đương với quy đổi: $\lambda = \frac{1}{C}$.

Tối ưu bằng Gradient Descent: Biến đổi ma trận

Với phần hinge loss, xét từng điểm dữ liệu (sử dụng trọng số gộp $\bar{w}$ và dữ liệu mở rộng $\bar{x}_n$), ta có hai trường hợp:

- **TH1:** Nếu $1 - y_n \bar{w}^T \bar{x}_n \leq 0$, ta có ngay đạo hàm theo $\bar{w}$ bằng 0.
- **TH2:** Nếu $1 - y_n \bar{w}^T \bar{x}_n > 0$, đạo hàm theo $\bar{w}$ chính là $-y_n \bar{x}_n$.

Để tính gradient cho toàn bộ dữ liệu, ta đặt:

$$Z = [y_1 \bar{x}_1, y_2 \bar{x}_2, \dots, y_N \bar{x}_N]$$

$$u = [y_1 \bar{w}^T \bar{x}_1, y_2 \bar{w}^T \bar{x}_2, \dots, y_N \bar{w}^T \bar{x}_N] = \bar{w}^T Z$$

với chú ý rằng u là một vector hàng.

Tối ưu bằng Gradient Descent: Quy tắc cập nhật

Tiếp tục, ta xác định các vị trí của u có giá trị nhỏ hơn 1 (thuộc **TH2**):

$$\mathcal{H} = \{n : u_n < 1\}$$

Đạo hàm theo $\bar{w}$ của hàm mất mát và quy tắc cập nhật là:

$$\nabla \mathcal{J}(\bar{w}) = \sum_{n \in \mathcal{H}} -y_n \bar{x}_n + \lambda \begin{bmatrix} w \\ 0 \end{bmatrix}$$

$$\bar{w} = \bar{w} - \eta \left(\sum_{n \in \mathcal{H}} -y_n \bar{x}_n + \lambda \begin{bmatrix} w \\ 0 \end{bmatrix} \right)$$

với η là *learning rate*.

Trực quan hóa ý tưởng: Bài toán 1 chiều


- **Bài toán 1 chiều (1D Data):** Xét dữ liệu phân loại trên một trục số duy nhất (ví dụ: liều lượng thuốc *Dosage*).
- **Thực trạng:** Các điểm xanh và đỏ đan xen lẫn nhau phức tạp.
- **Hạn chế:** Không thể tìm được một điểm ranh giới (threshold) đơn lẻ nào trên trục số để tách chúng.



Trực quan hóa ý tưởng: Ánh xạ không gian mới

• Hướng giải quyết của SVM:

- Đưa dữ liệu lên không gian cao hơn (dùng Dosage^2 làm trục tung y -axis).
- Tại không gian mới, dữ liệu được "kéo dẫn" lên cao.
- **Kết quả:** Dễ dàng tìm được đường ranh giới phân chia rạch ròi các nhóm dữ liệu!




Trực quan hóa ý tưởng: Đường biên phân loại

- **Hành động của mô hình:**

- Sau khi nâng chiều, **Support Vector Classifier** vẽ thành công một đường ranh giới (đường nét đứt màu hồng).
- Đường này phân tách hoàn toàn hai nhóm xanh và đỏ trong không gian mới.

- **Ứng dụng thực tế:** Giúp mô hình phân loại cực kỳ chính xác các điểm dữ liệu mới quan sát được!



Kernel Trick: Nâng chiều không tốn chi phí

1. Thách thức (Lời nguyền số chiều):

- Tính trực tiếp vector $\Phi(x)$ tại không gian siêu cao chiều gây bùng nổ tổ hợp, chi phí tính toán bất khả thi.

2. Giải pháp (Kernel Trick):

- Dữ liệu đôi ngẫu chỉ xuất hiện dưới dạng **tích vô hướng**: $\Phi(x_n)^T \Phi(x_m)$.
- Định nghĩa hàm kernel tính trực tiếp tại **không gian gốc**:

$$k(x, z) = \Phi(x)^T \Phi(z)$$

- **Ý nghĩa**: Thao tác trên dữ liệu đơn giản nhưng thu được sức mạnh của không gian vô hạn chiều!

Bài toán Đối ngẫu & Hàm quyết định mới

1. Bài toán tối ưu đối ngẫu (Kernelized Dual Problem):

$$\begin{aligned} \max_{\lambda} \quad & \sum_{n=1}^N \lambda_n - \frac{1}{2} \sum_{n=1}^N \sum_{m=1}^N \lambda_n \lambda_m y_n y_m k(x_n, x_m) \\ \text{s.t.} \quad & \sum_{n=1}^N \lambda_n y_n = 0 \quad \text{và} \quad 0 \leq \lambda_n \leq C, \quad \forall n = 1, 2, \dots, N \end{aligned}$$

2. Phương trình phân lớp điểm mới x:

$$f(x) = \text{sgn} \left(\sum_{m \in S} \lambda_m y_m k(x_m, x) + b \right)$$

Định lý Mercer (Hàm Kernel hợp lệ)

Một hàm $k(x, z)$ là Kernel hợp lệ (**Mercer Kernel**) khi thỏa mãn:

- 1. **Tính đối xứng:** $k(x, z) = k(z, x)$
- 2. **Ma trận Gram K Nửa xác định dương (PSD):**

$$v^T K v \geq 0, \quad \forall v \in \mathbb{R}^N$$

Ý nghĩa quan trọng

Đảm bảo hàm mục tiêu luôn là **hàm lồi (Convex)** $\rightarrow$ Thuật toán tối ưu luôn tìm được **nghiệm tối ưu toàn cục (Global Optimum)**!